

| S | (1,1) | (1,2) | (1,3) | (2,1) | (2,2) | (2,3) |
|-------|-------|-------------------------------|-------|-------------------------------|-----------------------------|-------|
| V_0 | 0 | 0 | 5 | 0 | 0 | -5 |
| V_1 | 0 | 0 | 5 | 0 | $0,8 \times (0,9 \times 5)$ | -5 |
| V_2 | 0 | $0,8 \times (0,9 \times 3,6)$ | 5 | $0,8 \times (0,9 \times 3,6)$ | $0,8 \times (0,9 \times 5)$ | -5 |

$$+ 0,1 \times (0,9 \times -5)$$

$$= 2,14$$

$$= 2,59$$

$$+ 0,1 \times (0,9 \times 3,6) = 3,92$$

2. Policy I با توجه به حدها، ارزشها، بالا محاسبه کنند (باز، خانه‌ها، که ده با چند Action با مقدار،

| | | |
|--------|---|----|
| $2,59$ | $3,92$ $3,6$ | +5 |
| S | $2,14$ | -5 |

طبق فرمول داده شده نسبت ارزشهای تابع

$$V_1((2,2)) = 0,8(0 + 0,9(5)) + 0,1(0 + 0,9(0)) + 0,1(0 + 0,9(0)) \\ = 3,6$$

$$V_2((2,1)) = 0,8(0 + 0,9(3,6)) + 0,1(0 + 0,9(0)) + 0,1(0 + 0,9(0)) \\ = 2,59$$

$$V_2((1,2)) = 0,8(0 + 0,9(3,6)) + 0,1(0 + 0,9(-5)) + 0,1(0 + 0,9(0)) \\ = 2,14$$

به نسبت با ورود ارزشهای تابع

$$V_2((2,2)) = 0,8(0 + 0,9(5)) + 0,1(0 + 0,9(3,6)) + 0,1(0 + 0,9(0)) \\ = 3,92$$

| S | (1,1) | (1,2) | (1,3) | (2,1) | (2,2) | (2,3) |
|------------|---------------|---------------|-------|---------------------|---------------------|-------|
| $\pi^*(S)$ | up \uparrow | up \uparrow | - | Right \rightarrow | Right \rightarrow | - |

2

| | | |
|-------------------------------|-------------------------------|----|
| 2,59 \rightarrow | 3,92 \rightarrow | +5 |
| 0 s \uparrow | \uparrow 2,14 | -5 |

$2,59 > 2,14 \xrightarrow{(1,1)} \text{so move up}$
 $3,92 > -5 \xrightarrow{(1,2)} \text{so move up}$

$3,92 > 9 \xrightarrow{(2,1)} \text{so move right}$
 $5 > 2,14 \xrightarrow{(2,2)} \text{so move right}$

: والله اعلم والله اعلم

| | | |
|------|-------------------------|----|
| 2,59 | 3,92 3,16 | +5 |
| S | 2,14 | -5 |

3! ترتبه

Summing all the rewards coming after the first visit to (S_t)

(1,1): For episode $E_1: G = 2,14 + (-5) = -2,86$
 $\sim \sim E_2: G = 2,14 + 3,92 + 5 = 11,06$
 $\sim \sim E_3: G = 2,59 + 3,92 + 5 = 11,51$

$$V((1,1)) = \frac{-2,86 + 11,06 + 11,51}{3} = 6,57$$

(2,2): For episode $E_1: G = \text{null}$

$\sim \sim E_2: G = 5$

$\sim \sim E_3: G = 5$

$$V((2,2)) = \frac{5+5}{3} = 3,33$$

4 در این قسمت فرض کردیم که agent با exploration policy نوعی کنه، یعنی

action ای که انتخاب می شود ، نرم خواهد بود .
برای تکامد Value ها طریع :

$$V(s_1)_{obs} = R(s_2) + V(s_2)$$

$$TD_{Error} = V(s_1)_{obs} - V(s_1)_{exp}$$

$$V(s_1) = V(s_1) + \alpha \times TD_{Error}$$

| | | |
|----|----|----|
| -1 | -1 | 5 |
| 2 | -1 | -5 |

| s | V(s) |
|-------|------|
| (1,1) | 0 |
| (1,2) | 0 |
| ⋮ | ⋮ |
| (2,3) | 0 |

حال دومیه زیر در نظریه گسترده

$$V((1,1)) = -0,1$$

$$V((1,2)) = -0,1$$

$$V((1,3)) = -5 + 0,1(4,5+5) = -4,05$$

| s | $V(s)$ |
|---------|---------|
| $(1,1)$ | $-0,1$ |
| $(1,2)$ | $-0,1$ |
| $(1,3)$ | $-4,05$ |
| $(2,1)$ | 0 |
| $(2,2)$ | 0 |
| $(2,3)$ | 0 |

بنابراین داریم:



$$v((1,1)) = -0,3$$

$$v((2,1)) = -0,1$$

$$v((2,2)) = -0,1$$

| | |
|---------|---------|
| $(1,1)$ | $-0,3$ |
| $(1,2)$ | $-0,1$ |
| $(1,3)$ | $-4,05$ |
| $(2,1)$ | $-0,1$ |
| $(2,2)$ | $-0,1$ |
| $(2,3)$ | 0 |

بنابر این داریم